Projekt - Analiza tržišta nekretnina Grupa FerovkeiFerovac

Marko Dodik, Silvija Gojević, Lucija Mičić, Antonia Žaja

19.12.2022.

Opis projekta:

Ovaj projekt obavezni dio je izbornog kolegija Statistička analiza podataka na Fakultetu elektrotehnike i računarstva. Svrha projekta je primjena teorijskih temelja stečenih na predavanjima na skup podataka iz stvarnog svijeta. Kao pomoć u izradi projekta korišten je programski jezik R koji je pružio potporu za izvođenje testiranja i bolju vizualizaciju podataka, te programski paket RStudio.

Opis problema:

Kupci često traže nekretnine sa određenim kriterijima (npr. određeni broj soba, veličina dvorišta), no takve "luksuze" ne žele preplatiti. Također, cijene nekretnina zbog razinih razloga znaju biti napuhane, dok je bankama u interesu objektivno procijeniti vrijednost nekretnine za potrebe kreditiranja klijenta. Upravo zato se prikupljaju podaci o prodanim nekretninama Cilj projektnog zadatka je analizirati te podatke i analizirati uspješnost prodaje nekretnina ovisno o značajkama koje ona sadrži.

```
#učitavanje podataka
data=read.csv('preprocessed_data.csv')
```

Skup podataka:

Skup podataka koji se koristi u ovom projektu predstavljaju informacije o prodanim nekretninama u gradu Ames (Iowa, Sjedinjenje Američke Države). Odnosi se na prodane nekretnine u sljedećim godinama: 2006., 2007., 2008., 2009. i 2010. Svaka nekretnina opisana je s 81 značajkom. Neke od značajki su kvadratura (LotArea), naziv susjedstva u kojem se nekretnina nalazi (Neighborhood), veličina podruma (TotalBsmtSF), tip krova (RoofStyle), broj spavaćih soba (Bedroom - nisu uračunate sobe u podrumu), lokacija garaže (GarageType) i slično. Ukupno je prikupljeno 1460 zapisa.

```
#prikaz svih značajki
names(data)
```

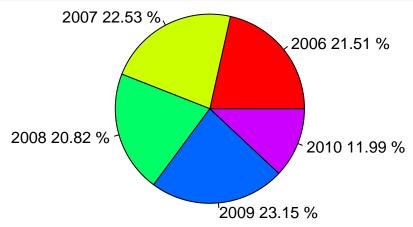
```
##
    [1] "Id"
                          "MSSubClass"
                                           "MSZoning"
                                                             "LotFrontage"
                                                             "LotShape"
##
    [5] "LotArea"
                          "Street"
                                           "Allev"
##
    [9]
        "LandContour"
                          "Utilities"
                                           "LotConfig"
                                                             "LandSlope"
                                           "Condition2"
                                                             "BldgType"
##
   [13]
        "Neighborhood"
                          "Condition1"
        "HouseStyle"
                          "OverallQual"
                                           "OverallCond"
                                                             "YearBuilt"
   [17]
   [21]
        "YearRemodAdd"
                          "RoofStyle"
                                           "RoofMatl"
                                                             "Exterior1st"
        "Exterior2nd"
                          "MasVnrType"
                                           "MasVnrArea"
                                                             "ExterQual"
   [25]
   [29]
        "ExterCond"
                          "Foundation"
                                           "BsmtQual"
                                                             "BsmtCond"
                          "BsmtFinType1"
        "BsmtExposure"
                                           "BsmtFinSF1"
                                                             "BsmtFinType2"
  [33]
   [37]
        "BsmtFinSF2"
                          "BsmtUnfSF"
                                           "TotalBsmtSF"
                                                             "Heating"
                          "CentralAir"
                                                             "X1stFlrSF"
   [41]
        "HeatingQC"
                                           "Electrical"
   [45]
        "X2ndFlrSF"
                          "LowQualFinSF"
                                           "GrLivArea"
                                                             "BsmtFullBath"
  [49] "BsmtHalfBath"
                          "FullBath"
                                           "HalfBath"
                                                             "BedroomAbvGr"
```

```
## [53] "KitchenAbvGr"
                         "KitchenQual"
                                         "TotRmsAbvGrd"
                                                          "Functional"
  [57] "Fireplaces"
                         "FireplaceQu"
                                         "GarageType"
                                                          "GarageYrBlt"
##
## [61] "GarageFinish"
                         "GarageCars"
                                         "GarageArea"
                                                          "GarageQual"
## [65] "GarageCond"
                         "PavedDrive"
                                         "WoodDeckSF"
                                                          "OpenPorchSF"
##
  [69] "EnclosedPorch" "X3SsnPorch"
                                         "ScreenPorch"
                                                          "PoolArea"
## [73] "PoolQC"
                         "Fence"
                                         "MiscFeature"
                                                          "MiscVal"
## [77] "MoSold"
                         "YrSold"
                                         "SaleType"
                                                          "SaleCondition"
## [81] "SalePrice"
#ukupni broj zapisa
nrow(data)
```

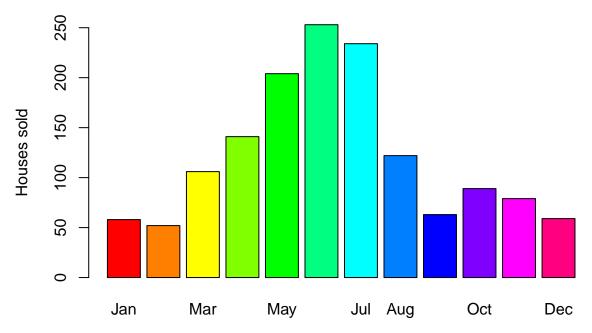
[1] 1460

Deskriptivna statistika skupa podataka:

Proučavamo tržište nekretnina u godinama od periodu od 2006. do 2010. godine (uključivo). Na sljedećem dijagramu, prikazani su udjeli broja prodanih nekretnina po godinama. Iz njega vidimo kako je 2009. godine prodan najveći broj nekretnina (23.15%). Za prikaz ovih podataka je odabran strukturni krug.

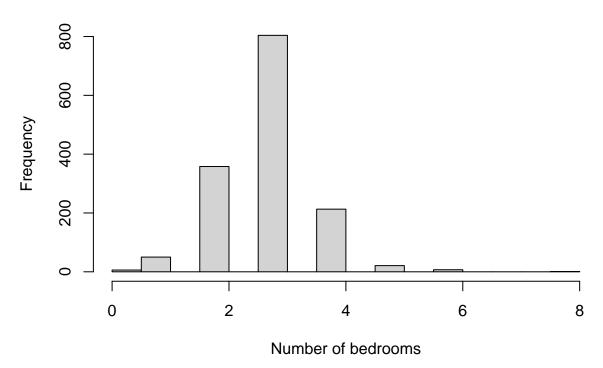


Zanimljiva informacija koja se može saznati iz danih podataka je u kojim mjesecima se tijekom godina najviše nekretnina prodalo. Iz sljedećeg stupičastog dijagrama vidimo kako je to u kasnim proljetnim i ljetnim mjesecima.



Sljedeći dijagram prikazuje broj spavaćih soba prodanih nekretnina. Iz njega možemo zaključiti da prosječni broj spavaćih soba prodanih nekretnina iznosi 3. Najmanji broj spavaćih soba među prikupljenim podacima je 0, a najveći 8. Za prikaz ovih podataka odabran je histogram, broj razreda je 25.

Bedroom number histogram



```
#prosječan broj spavaćih soba
mean(data$BedroomAbvGr)
```

[1] 2.866438

S obzirom da je najveći broj prodanih nekretnina bio 2009. godine, zanima nas prosječni broj spavaćih soba te godine u usporedbi s ostalim godinama.

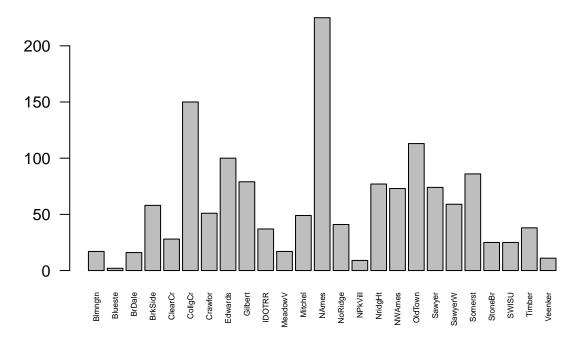
```
#prikaz podataka u obliku tablice radi preglednosti
as.data.frame(t(df)) %>% kable(col.names = NULL)
```

year	2006	2007	2008	2009	2010
bedrooms	2.872611	2.951368	2.855263	2.784024	2.874286

Sljedeći dijagram prikazuje distribuciju prodanih nekretnina u ovisnosi o kvartu u kojem se nalaze. Iz dijagrama je vidljivo da se najveći broj prodanih nekretnina nalazi u kvartu North Ames. Za prikaz podataka korišten je stupičasti dijagram.

```
blmngtn = which(data$Neighborhood=='Blmngtn')/1460*100
blueste = which(data$Neighborhood=='BrDale')/1460*100
brdale = which(data$Neighborhood=='BrDale')/1460*100
brkside = which(data$Neighborhood=='BrkSide')/1460*100
clearcr = which(data$Neighborhood=='ClearCr')/1460*100
collgcr = which(data$Neighborhood=='CollgCr')/1460*100
crawfor = which(data$Neighborhood=='Crawfor')/1460*100
edwards = which(data$Neighborhood=='Edwards')/1460*100
gilbert = which(data$Neighborhood=='Gilbert')/1460*100
IDOTRR = which(data$Neighborhood=='IDOTRR')/1460*100
barplot(table(data$Neighborhood),las=2,cex.names=.5,main='Sold houses per neighborhood')
```

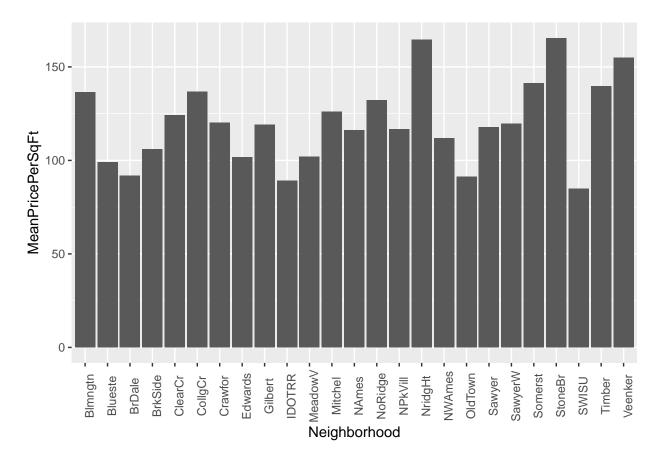
Sold houses per neighborhood



Nadalje, mogli bi se zapitati koja je prosječna cijena kvadrata po kvartu, kako bi dobili bolji uvid u poželjnije kvartove za život. Na temelju stupičastog dijagrama, zaključujemo kako su cijene nekretnina najpovoljnije u kvartu South & West of Iowa State University, a najskuplje u Stone Brook kvartu.

```
data$PricePerSqFt <- data$SalePrice / data$GrLivArea
data_by_neighborhood <- data %>% group_by(Neighborhood) %>%
   summarize(MeanPricePerSqFt = mean(PricePerSqFt))

ggplot(data_by_neighborhood, aes(x = Neighborhood, y = MeanPricePerSqFt)) +
   geom_bar(stat = "identity")+ theme(axis.text.x = element_text(angle = 90))
```

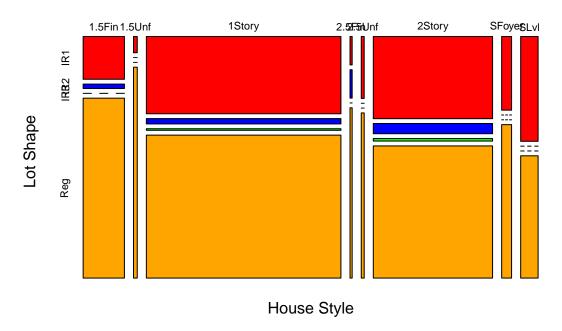


Statističko zaključivanje

Ovisnost broja katova nekretnine o obliku zemljišne čestice

Svaka nekretnina ima određeni oblik (IR1, IR2, IR3, Reg). Zanima nas razlikuje li se broj katova nekretnine obzirom na njen oblik, odnosno želimo provjeriti imaju li nekretnine određenog oblika veći broj katova nego ostale. Kako bi provjerili postoji li veza koja bi objasnila ovisnost tih dvaju atributa, provodimo hi-kvadrat test. Testom utvrđujemo p-vrijednost, koja je manja od 0.05, stoga zaključujemo da broj katova nekretnine ne ovisi o obliku čestice.

House Style by Shape of Lot

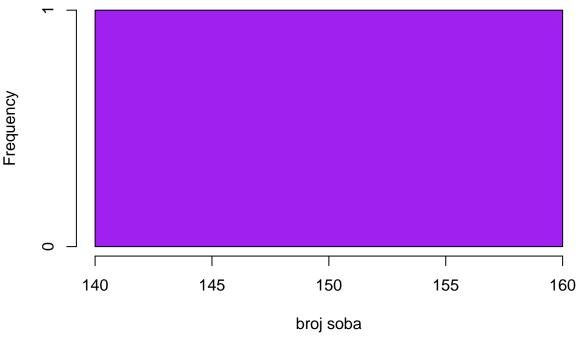


Ovisnost cijene kvadrata nekretnine o broju spavaćih soba

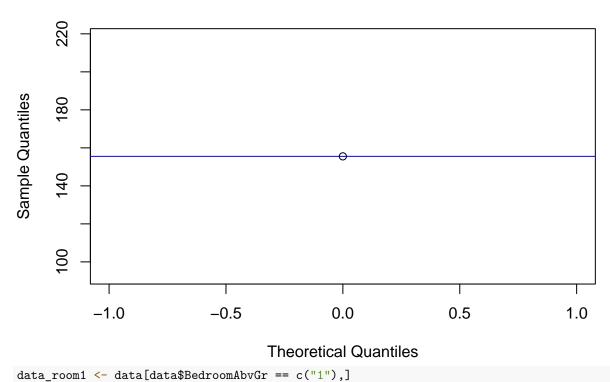
Za utvrđivanje postoji li ovisnost između cijene kvadrata i broja spavaćih soba provest ćemo ANOVA test. ANOVA (analiza varijance) je statistički test koji se koristi za usporedbu srednjih vrijednosti više od dvije grupe. Često je dobro rješenje kada želimo utvrditi postoji li značajna razlika između srednjih vrijednosti više od dvije grupe, jer nam omogućuje testiranje više grupa odjednom. U kontekstu zadanog skupa podataka, ANOVA je dobro rješenje jer želimo usporediti srednje vrijednosti cijene po kvadratnom metru za nekretnine s različitim brojem spavaćih soba. P-vrijednost za ovaj test iznosi zanemarivih <2e-16, što nam govori da postoji značajna razlika između srednjih vrijednosti grupa.

```
data_room0 <- data[data$BedroomAbvGr == c("0"),]
hist(mean(data_room0$SalePrice/data_room0$GrLivArea),
    main = "Cijena kvadrata nekretnina koje nemaju sobe",
    col="purple", xlab="broj soba")</pre>
```

Cijena kvadrata nekretnina koje nemaju sobe



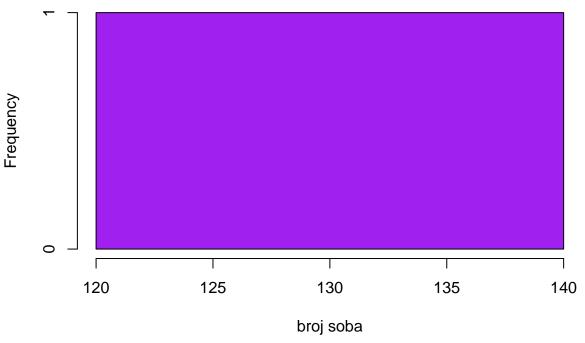
Cijena kvadrata nekretnina koje nemaju sobe



```
hist(mean(data_room1$SalePrice/data_room0$GrLivArea),
    main = "Cijena kvadrata nekretnina koje imaju 1 sobu",
    col="purple", xlab="broj soba")
```

Warning in data_room1\$SalePrice/data_room0\$GrLivArea: longer object length is
not a multiple of shorter object length

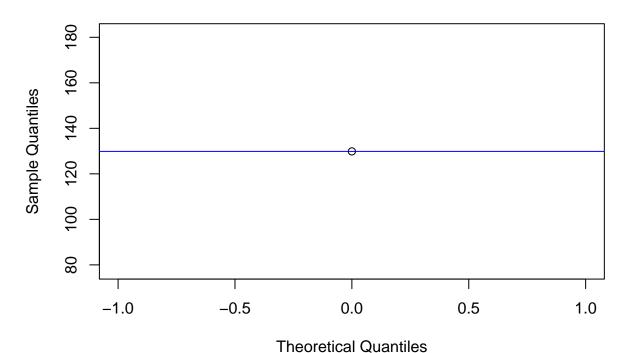
Cijena kvadrata nekretnina koje imaju 1 sobu



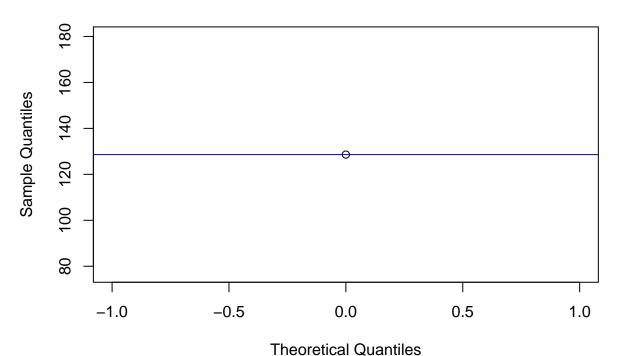
```
## Warning in data_room1$SalePrice/data_room0$GrLivArea: longer object length is
## not a multiple of shorter object length
qqline(mean(data_room1$SalePrice/data_room0$GrLivArea), col="blue")
```

Warning in data_room1\$SalePrice/data_room0\$GrLivArea: longer object length is
not a multiple of shorter object length

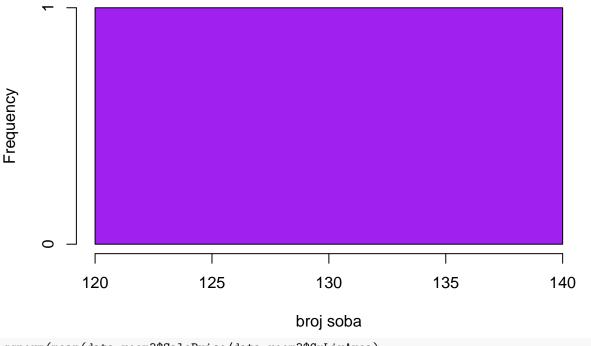
Cijena kvadrata nekretnina koje imaju 1 sobu



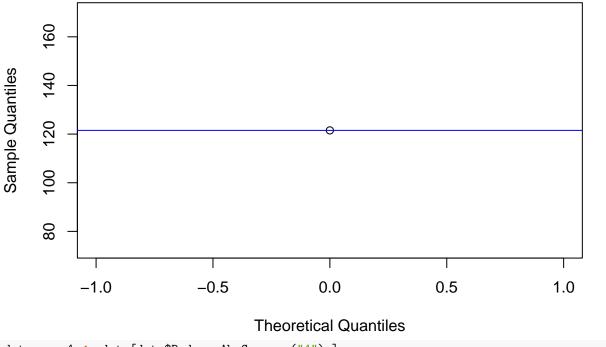
Cijena kvadrata nekretnina koje imaju 2 sobe



Cijena kvadrata nekretnina koje imaju 3 sobe

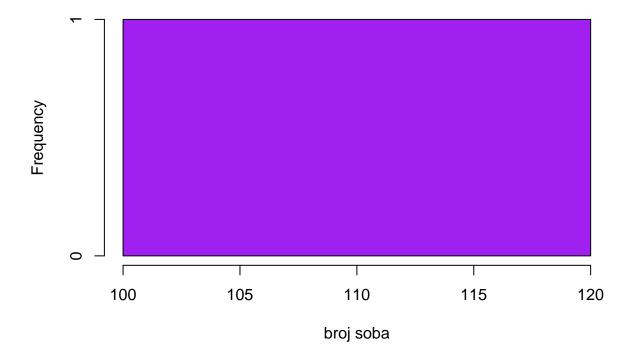


Cijena kvadrata nekretnina koje imaju 3 sobe

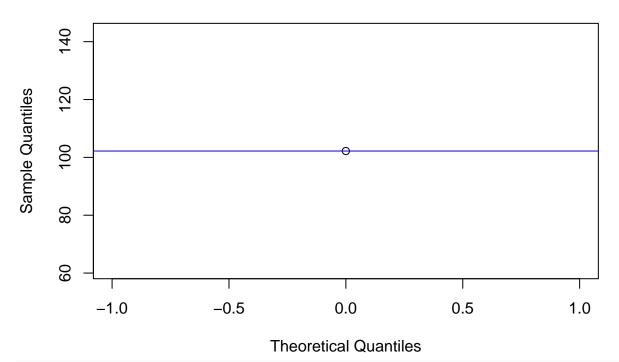


```
data_room4 <- data[data$BedroomAbvGr == c("4"),]
hist(mean(data_room4$SalePrice/data_room4$GrLivArea),
    main = "Cijena kvadrata nekretnina koje imaju 4 sobe",
    col="purple", xlab="broj soba")</pre>
```

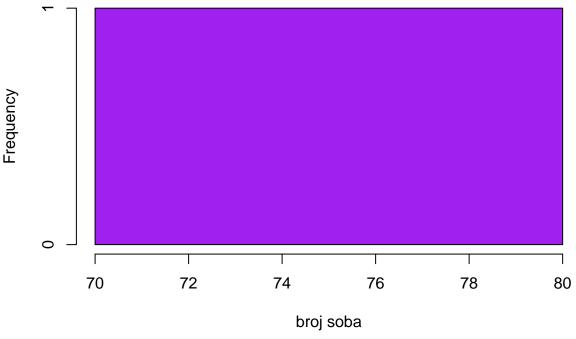
Cijena kvadrata nekretnina koje imaju 4 sobe



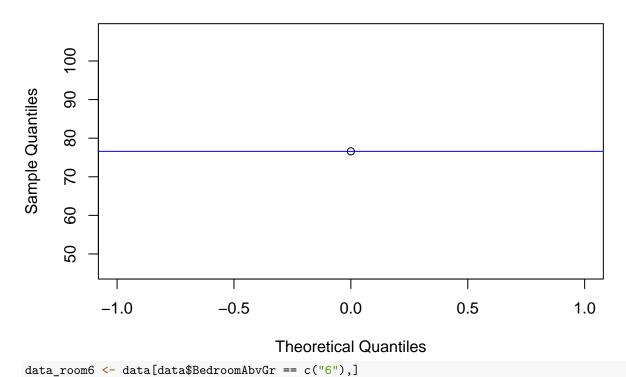
Cijena kvadrata nekretnina koje imaju 4 sobe



Cijena kvadrata nekretnina koje imaju 5 sobe

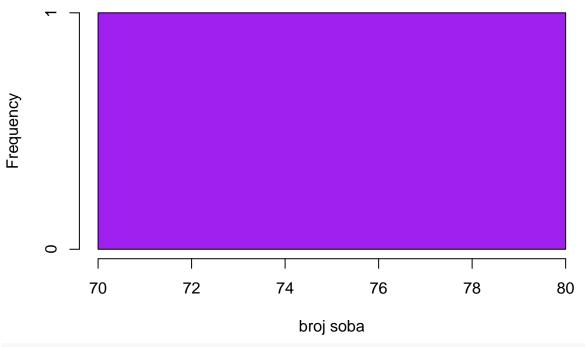


Cijena kvadrata nekretnina koje imaju 5 sobe

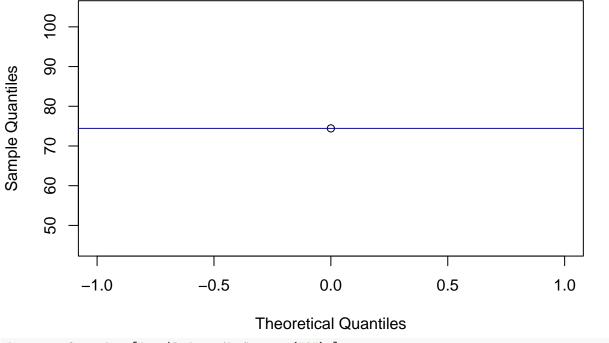


```
hist(mean(data_room6$SalePrice/data_room6$GrLivArea),
    main = "Cijena kvadrata nekretnina koje imaju 6 soba",
    col="purple", xlab="broj soba")
```

Cijena kvadrata nekretnina koje imaju 6 soba

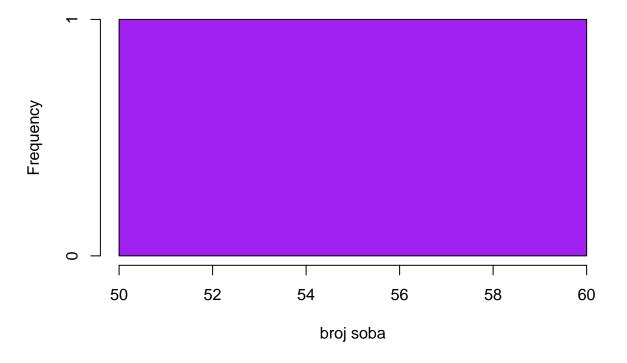


Cijena kvadrata nekretnina koje imaju 6 soba

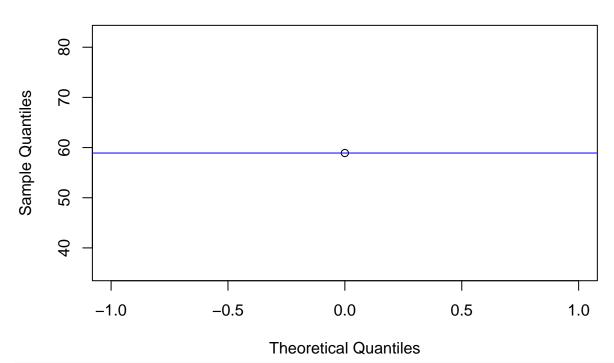


```
data_room8 <- data[data$BedroomAbvGr == c("8"),]
hist(mean(data_room8$SalePrice/data_room8$GrLivArea),
    main = "Cijena kvadrata nekretnina koje imaju 8 soba",
    col="purple", xlab="broj soba")</pre>
```

Cijena kvadrata nekretnina koje imaju 8 soba



Cijena kvadrata nekretnina koje imaju 8 soba



var(na.omit(mean(data_room0\$SalePrice/data_room0\$GrLivArea)))

```
## [1] NA
```

var(na.omit(mean(data_room1\$SalePrice/data_room1\$GrLivArea)))

[1] NA

var(na.omit(mean(data_room2\$SalePrice/data_room2\$GrLivArea)))

[1] NA

var(na.omit(mean(data_room3\$SalePrice/data_room3\$GrLivArea)))

[1] NA

var(na.omit(mean(data_room4\$SalePrice/data_room4\$GrLivArea)))

[1] NA

var(na.omit(mean(data_room5\$SalePrice/data_room5\$GrLivArea)))

[1] NA

var(na.omit(mean(data_room6\$SalePrice/data_room6\$GrLivArea)))

[1] NA

var(na.omit(mean(data_room8\$SalePrice/data_room8\$GrLivArea)))

[1] NA

```
res.aov <- aov( SalePrice/GrLivArea~ BedroomAbvGr, data = data)
summary(res.aov)
##
                     Sum Sq Mean Sq F value Pr(>F)
## BedroomAbvGr
                     182177
                              182177
                                       211.6 <2e-16 ***
                   1
## Residuals
                1458 1255521
                                 861
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
data_by_bedrooms <- data %>%
  group_by(BedroomAbvGr)%>%
  summarize(mean_price_sqft =mean(SalePrice/GrLivArea),
            sd_price_sqft=sd(SalePrice/GrLivArea))
 ggplot(data = data_by_bedrooms,
        aes(x = BedroomAbvGr, y = mean_price_sqft)) + geom_bar(stat = "identity")
  150 -
mean_price_sqft
   50 -
             Ö
                              2
                                                                6
                                                                                 8
                                               4
                                        BedroomAbvGr
```

ZAKLJUČAK: odbacujemo nultu hipotezu, to jest cijena kvadrata nekretnine ne ovisi o broju spavaćih soba

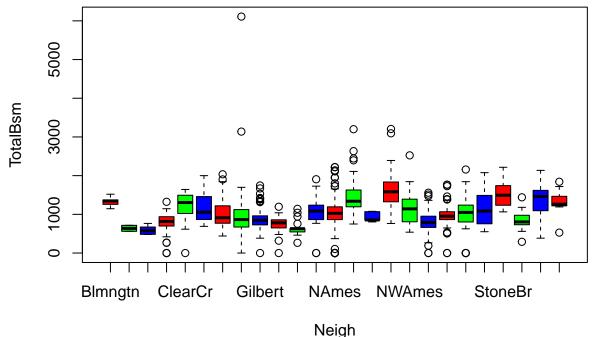
Ovisi li velicina podruma o kvartu u gradu

Svaka prodana nekretnina nalazi se u određenom naselju i ima određenu veličinu podruma. Zanima nas razlikuju li se uspješnosti prodaje nekretnina u određenom naselju s obzirom na veličinu podruma.

```
data_by_neighborhood <- data %>% group_by(data$Neighborhood)
print(data_by_neighborhood)
```

```
## # A tibble: 1,460 x 83
  # Groups:
                data$Neighborhood [25]
         Id MSSubClass MSZon~1 LotFr~2 LotArea Street Alley LotSh~3 LandC~4 Utili~5
##
##
      <int>
                  <int> <chr>
                                   <int>
                                            <int> <chr>
                                                         <chr> <chr>
                                                                        <chr>
                                                                                 <chr>
##
    1
          1
                     60 RL
                                      65
                                             8450 Pave
                                                          <NA>
                                                                Reg
                                                                        Lvl
                                                                                 AllPub
                                                                                 AllPub
          2
                     20 RL
                                      80
                                             9600 Pave
                                                         <NA>
##
    2
                                                                Reg
                                                                        Lvl
##
    3
          3
                     60 RL
                                      68
                                           11250 Pave
                                                         <NA>
                                                                IR1
                                                                        Lvl
                                                                                 AllPub
    4
##
          4
                     70 RL
                                      60
                                            9550 Pave
                                                         <NA>
                                                                IR1
                                                                        Lvl
                                                                                 AllPub
##
    5
          5
                     60 RL
                                      84
                                           14260 Pave
                                                         <NA>
                                                                IR1
                                                                        Lvl
                                                                                 AllPub
                                      85
##
    6
          6
                     50 RL
                                           14115 Pave
                                                         <NA>
                                                                IR1
                                                                        Lvl
                                                                                 AllPub
##
    7
          7
                     20 RL
                                      75
                                           10084 Pave
                                                          <NA>
                                                                        Lvl
                                                                                 AllPub
                                                                Reg
##
    8
          8
                     60 RL
                                      NA
                                           10382 Pave
                                                         <NA>
                                                                IR1
                                                                        Lvl
                                                                                 AllPub
##
    9
          9
                     50 RM
                                      51
                                             6120 Pave
                                                          <NA>
                                                                        Lvl
                                                                Reg
                                                                                 AllPub
                                            7420 Pave
   10
                                      50
                                                         <NA>
##
         10
                    190 RL
                                                                        Lvl
                                                                                 AllPub
                                                                Reg
##
         with 1,450 more rows, 73 more variables: LotConfig <chr>,
       LandSlope <chr>, Neighborhood <chr>, Condition1 <chr>, Condition2 <chr>,
##
       BldgType <chr>, HouseStyle <chr>, OverallQual <int>, OverallCond <int>,
##
       YearBuilt <int>, YearRemodAdd <int>, RoofStyle <chr>, RoofMatl <chr>,
##
       Exterior1st <chr>, Exterior2nd <chr>, MasVnrType <chr>, MasVnrArea <int>,
##
       ExterQual <chr>, ExterCond <chr>, Foundation <chr>, BsmtQual <chr>,
## #
## #
       BsmtCond <chr>, BsmtExposure <chr>, BsmtFinType1 <chr>, ...
boxplot(data_by_neighborhood$TotalBsmtSF
        ~ data_by_neighborhood$Neighborhood,
        ylab = "TotalBsm",
```





1500

1400

1300

200

Velicina podruma u Blmngtn Velicina podruma u Blmngtn Selicina podruma u Blmngtn Selicina podruma u Blmngtn Velicina podruma u Blmngtn Selicina podruma u Blmngtn Selicina podruma u Blmngtn

0

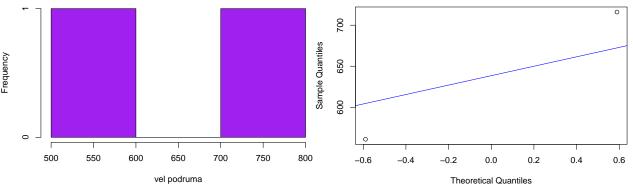
Theoretical Quantiles

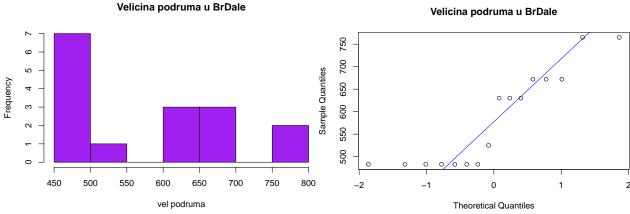
Velicina podruma u Blmngtn

data_re2 <- data[data\$Neighborhood == c("Blueste"),]
hist(data_re2\$TotalBsm,
 main = "Velicina podruma u Blueste",
 col="purple", xlab="vel podruma")
qqnorm(data_re2\$TotalBsmtSF, main="Velicina podruma u Blueste")
qqline(data_re2\$TotalBsmtS, col="blue")</pre>

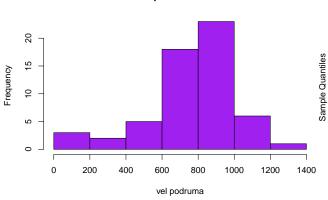
Velicina podruma u Blueste

Velicina podruma u Blueste





```
data_re4 <- data[data$Neighborhood == c("BrkSide"),]
hist(data_re4$TotalBsm,
    main = "Velicina podruma u BrkSide",
    col="purple", xlab="vel podruma")
qqnorm(data_re4$TotalBsmtSF, main="Velicina podruma u BrkSide")
qqline(data_re4$TotalBsmtS, col="blue")</pre>
```



Velicina podruma u BrkSide

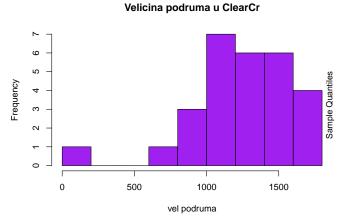
000 - 0

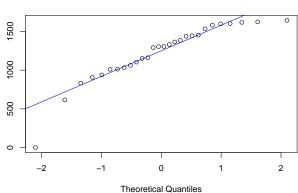
Theoretical Quantiles

Velicina podruma u ClearCr

Velicina podruma u BrkSide

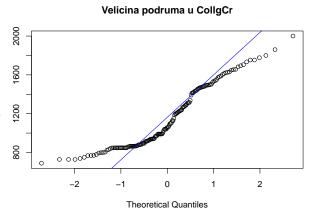
```
data_re5 <- data[data$Neighborhood == c("ClearCr"),]
hist(data_re5$TotalBsm,
    main = "Velicina podruma u ClearCr",
    col="purple", xlab="vel podruma")
qqnorm(data_re5$TotalBsmtSF, main="Velicina podruma u ClearCr")
qqline(data_re5$TotalBsmtS, col="blue")</pre>
```





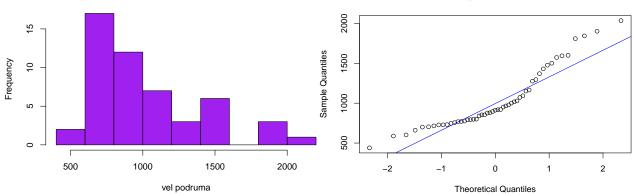
```
data_re6 <- data[data$Neighborhood == c("CollgCr"),]
hist(data_re6$TotalBsm,
    main = "Velicina podruma u CollgCr",
    col="purple", xlab="vel podruma")
qqnorm(data_re6$TotalBsmtSF, main="Velicina podruma u CollgCr")
qqline(data_re6$TotalBsmtS, col="blue")</pre>
```

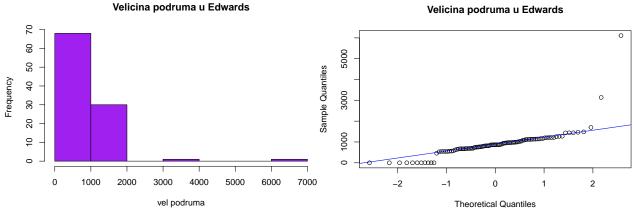
Velicina podruma u CollgCr Sample Quantiles Frequency vel podruma

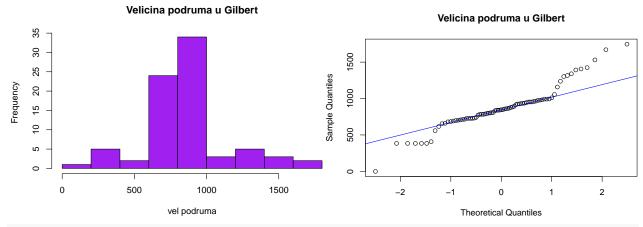


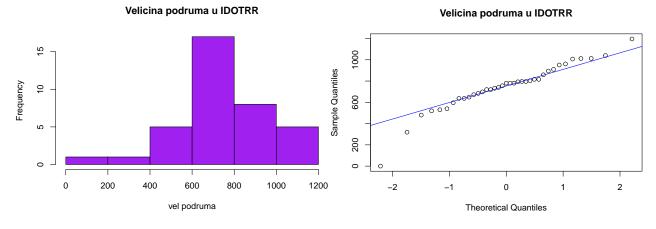
Velicina podruma u Crawfor

Velicina podruma u Crawfor





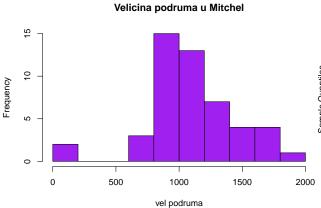


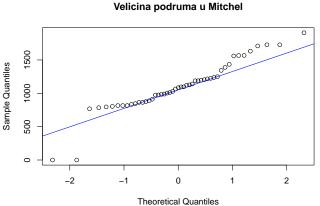


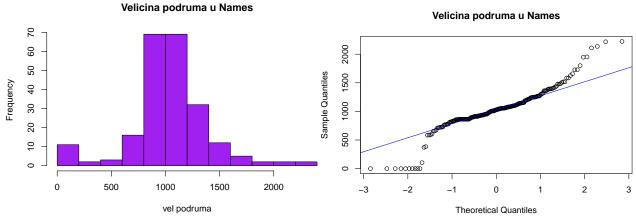
Velicina podruma u MeadowV Lednency Sample Onautiles 20 400 600 800 1000 1200

vel podruma

Velicina podruma u MeadowV

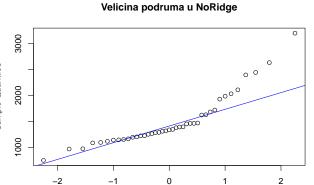




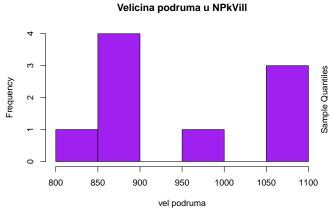


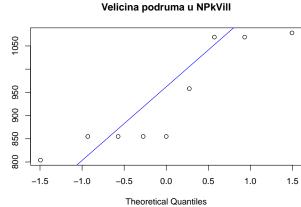
Preguency vel podruma

Velicina podruma u NoRidge



```
data_re15 <- data[data$Neighborhood == c("NPkVill"),]
hist(data_re15$TotalBsm,
    main = "Velicina podruma u NPkVill",
    col="purple", xlab="vel podruma")
qqnorm(data_re15$TotalBsmtSF, main="Velicina podruma u NPkVill")
qqline(data_re15$TotalBsmtS, col="blue")</pre>
```





3000

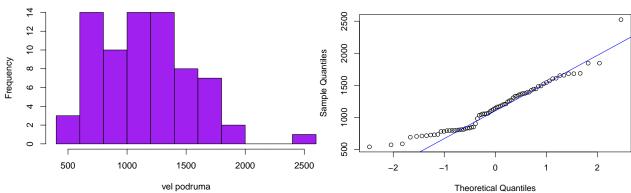
1000

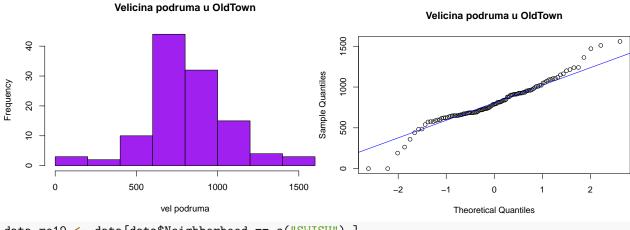
2

Velicina podruma u NridgHt

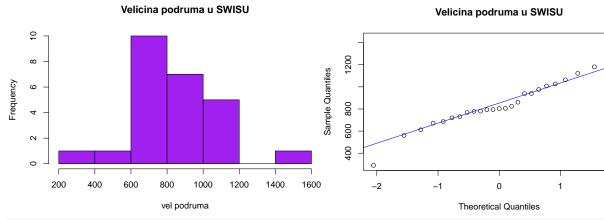
Velicina podruma u NWAmes

Velicina podruma u NWAmes

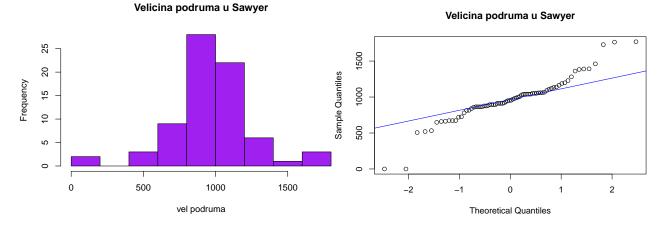




```
data_re19 <- data[data$Neighborhood == c("SWISU"),]
hist(data_re19$TotalBsm,
    main = "Velicina podruma u SWISU",
    col="purple", xlab="vel podruma")
qqnorm(data_re19$TotalBsmtSF, main="Velicina podruma u SWISU")
qqline(data_re19$TotalBsmtS, col="blue")</pre>
```



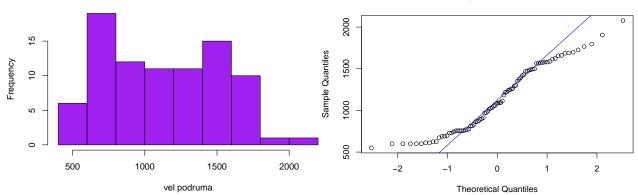
```
data_re20 <- data[data$Neighborhood == c("Sawyer"),]
hist(data_re20$TotalBsm,
    main = "Velicina podruma u Sawyer",
    col="purple", xlab="vel podruma")
qqnorm(data_re20$TotalBsmtSF, main="Velicina podruma u Sawyer")
qqline(data_re20$TotalBsmtS, col="blue")</pre>
```

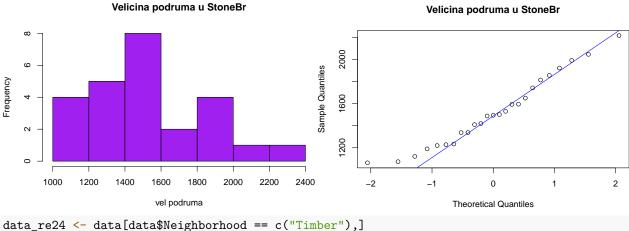


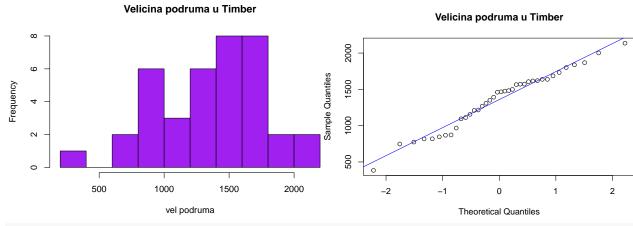
Velicina podruma u SawyerW

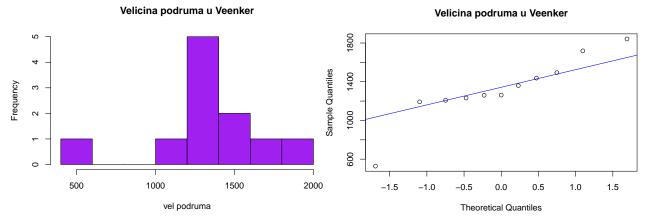
Velicina podruma u Somerst

Velicina podruma u Somerst









Pretpostavke ANOVA testa su: populacije iz grupa međusobno su nezavisne i normalno distribuirane sa jednakim varijancama. Nezavisnost populacija teško možemo provjeriti stoga ćemo pretpostaviti da su one nezavisne.

U nastavku vidimo da se varijance populacija razlikuju.

```
var(na.omit(data_re1$TotalBsmtSF))
## [1] 7044.632
var(na.omit(data_re2$TotalBsmtSF))
## [1] 12012.5
var(na.omit(data_re3$TotalBsmtSF))
## [1] 11332.65
var(na.omit(data_re4$TotalBsmtSF))
## [1] 71214.7
var(na.omit(data_re5$TotalBsmtSF))
## [1] 133217.7
var(na.omit(data_re6$TotalBsmtSF))
## [1] 102206.2
var(na.omit(data_re7$TotalBsmtSF))
## [1] 141672.3
var(na.omit(data_re8$TotalBsmtSF))
## [1] 474460.2
var(na.omit(data_re9$TotalBsmtSF))
## [1] 84038.51
var(na.omit(data_re10$TotalBsmtSF))
## [1] 46982.47
var(na.omit(data_re11$TotalBsmtSF))
## [1] 45855.37
var(na.omit(data_re12$TotalBsmtSF))
## [1] 137851.3
var(na.omit(data_re13$TotalBsmtSF))
## [1] 134922
var(na.omit(data_re14$TotalBsmtSF))
## [1] 246306.6
var(na.omit(data_re15$TotalBsmtSF))
## [1] 12452.36
```

```
var(na.omit(data_re16$TotalBsmtSF))
## [1] 193546.7
var(na.omit(data_re17$TotalBsmtSF))
## [1] 142499.5
var(na.omit(data_re18$TotalBsmtSF))
## [1] 66447.66
var(na.omit(data_re19$TotalBsmtSF))
## [1] 51548.33
var(na.omit(data_re20$TotalBsmtSF))
## [1] 91153.92
var(na.omit(data_re21$TotalBsmtSF))
## [1] 176793.2
var(na.omit(data_re22$TotalBsmtSF))
## [1] 155278.7
var(na.omit(data_re23$TotalBsmtSF))
## [1] 101834
U nastavku je prikazan pravokutni dijagram za sve grupe.
boxplot(data$TotalBsmtSF[data$Neighborhood != "<undefined>"]
        ~ data$Neighborhood[data$Neighborhood != "<undefined>"],
        ylab= "Total Besment",
        xlab= "Neighbourhood",
        col=rainbow(3))
Total Besment
   1000
      Blmngtn ClearCr Gilbert
                        NAmes NWAmes
                      Neighbourhood
```

Pretpostavljamo da su sredine svih grupa jednake te uz gore navedene pretpostavke provodimo ANOVA test o jednakosti sredina. Nulta hipoteza je da su sredine za sve grupe jednake, a alternativna hipoteza je da se razlikuju.

```
res.aov <- aov( TotalBsmtSF~ factor(data$Neighborhood), data = data)
summary(res.aov)

## Df Sum Sq Mean Sq F value Pr(>F)
## factor(data$Neighborhood) 24 74574228 3107259 21.62 <2e-16 ***</pre>
```

```
## Residuals 1435 206228358 143713
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

Iz rezultata ANOVA testa možemo zaključiti da sredine tih uzoraka nisu jednake te odbaciti nultu hipotezu u korist tvrdnje da su sredine različite. ANOVA nam samo govori da su sredine tih kategorija međusobno različite.

Ovisnost cijene o veličini nekretnine:

Provjeravamo linearnu zavisnost veličine nekretnine i cijene. Intuitivno bi se dalo naslutiti da će veće nekretnine imati veću cijenu.

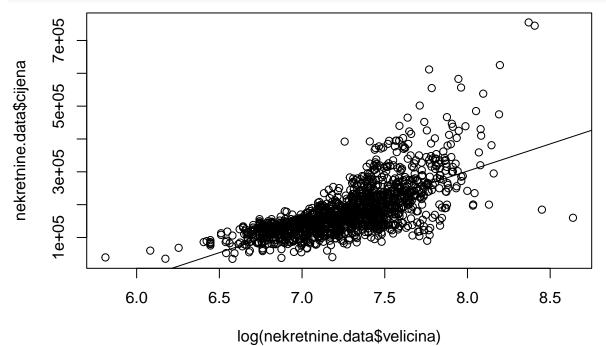
```
nekretnine.data = data[,c("GrLivArea","SalePrice")]
colnames(nekretnine.data) = c("velicina", "cijena")
nekretnine.data = na.omit(nekretnine.data)

log_velicina = log(nekretnine.data$velicina)

plot(log(nekretnine.data$velicina), nekretnine.data$cijena)

fit.velicine = lm(nekretnine.data$cijena~log_velicina)

abline(fit.velicine)
```



```
summary(fit.velicine)
```

```
##
## Call:
## lm(formula = nekretnine.data$cijena ~ log_velicina)
##
## Residuals:
##
                                 3Q
       Min
                 1Q
                    Median
                                         Max
## -247772
                              24759
                                     391583
           -31767
                      -1680
```

```
##
## Coefficients:
##
                Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1022316
                              32624
                                    -31.34
                                              <2e-16 ***
## log_velicina
                  165558
                               4484
                                      36.92
                                              <2e-16 ***
##
                  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## Signif. codes:
##
## Residual standard error: 57130 on 1458 degrees of freedom
## Multiple R-squared: 0.4832, Adjusted R-squared: 0.4828
## F-statistic: 1363 on 1 and 1458 DF, p-value: < 2.2e-16
c("Pearson", cor(log_velicina, nekretnine.data$cijena, method = "pearson",
                 use = "complete.obs"))
```

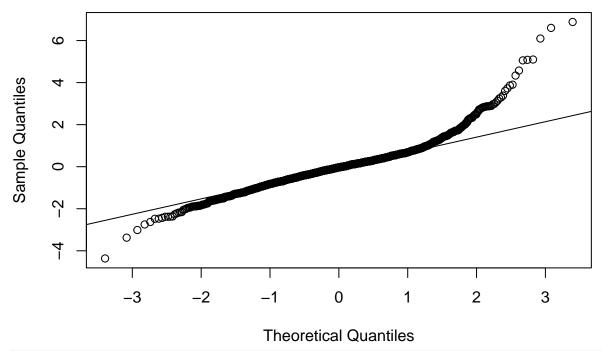
[1] "Pearson" "0.695118068246328"

Prema Pearsonovom koeficijentu, vidimo da su varijable zavisne što je bilo i za očekivati.

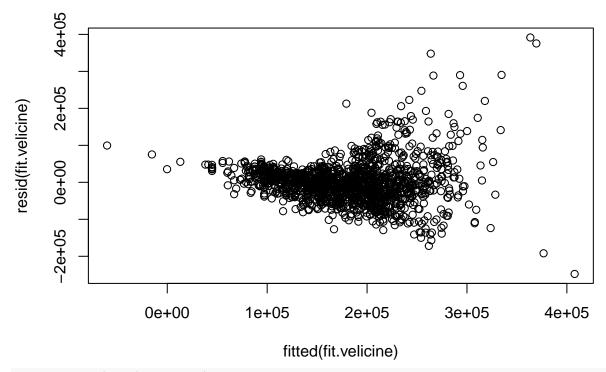
U nastavku prikazujemo Q-Q plot i graf reziduala

```
qqnorm(rstandard(fit.velicine))
qqline(rstandard(fit.velicine))
```

Normal Q-Q Plot



plot(fitted(fit.velicine), resid(fit.velicine))



shapiro.test(data\$GrLivArea)#odbacujemo nultu hipotezu da su podaci normalni

```
##
## Shapiro-Wilk normality test
##
## data: data$GrLivArea
## W = 0.92798, p-value < 2.2e-16
shapiro.test(data$SalePrice)#odbacujemo nultu hipotezu da su podaci normalni</pre>
```

```
##
## Shapiro-Wilk normality test
##
## data: data$SalePrice
## W = 0.86967, p-value < 2.2e-16</pre>
```

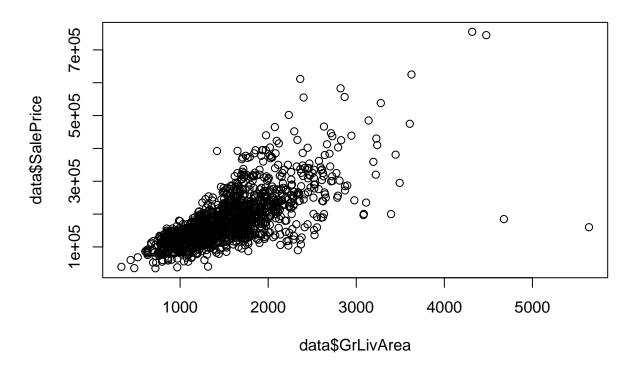
Kako bi znali predvidjeti cijenu nekretnine, možemo ispitati različite varijable koje bi mogle utjecati na cijenu:

- veličina nekretnine
- $\bullet \;$ godina izgradnje
- broj soba

```
plot(data$GrLivArea,data$SalePrice) #kvadratura vs cijena

fit.livarea = lm(SalePrice~GrLivArea,data=data)

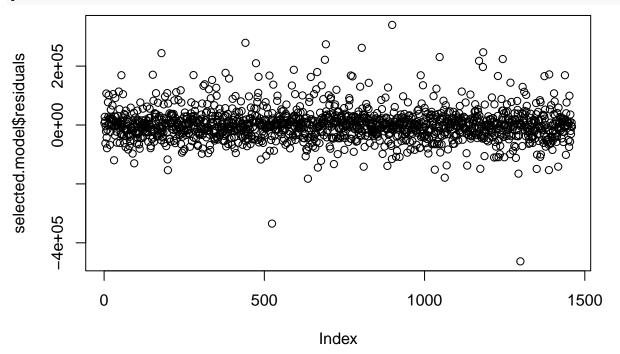
plot(data$GrLivArea,data$SalePrice)
lines(data$GrLivArea,fit.livarea$SalePrice,col='red')
```



Normalnost reziduala i homogenost varijance

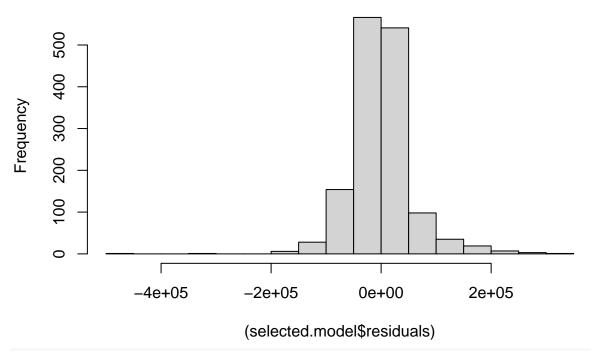
Normalnost reziduala moguće je provjeriti grafički, pomoću kvantil-kvantil plota (usporedbom s linijom normalne razdiobe), te statistički pomoću Kolmogorov-Smirnovljevog testa.

selected.model = fit.livarea
plot(selected.model\$residuals)



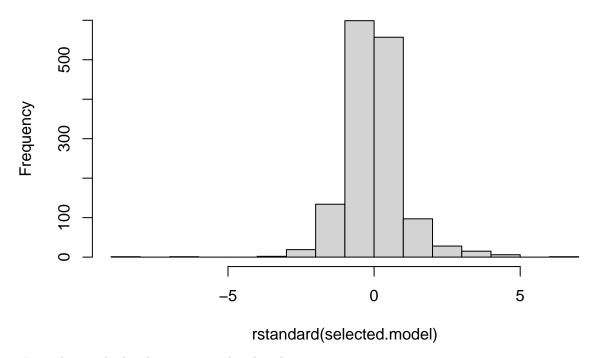
hist((selected.model\$residuals))

Histogram of (selected.model\$residuals)



hist(rstandard(selected.model))

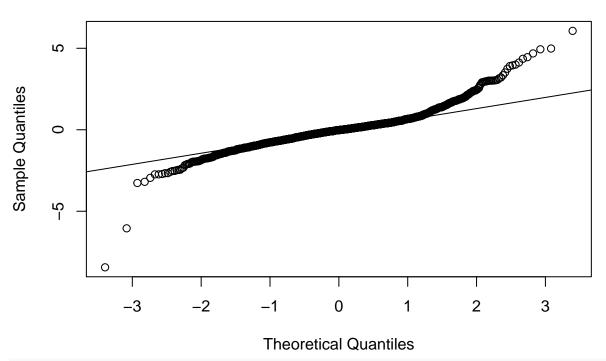
Histogram of rstandard(selected.model)



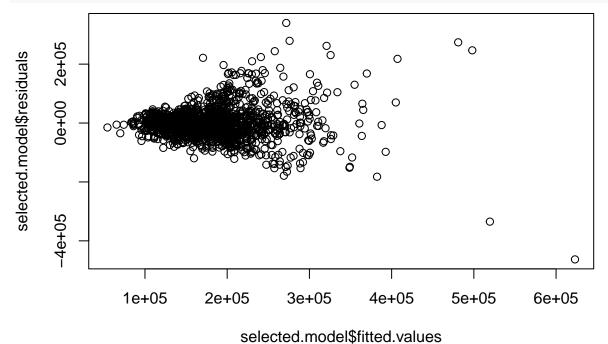
q-qplot reziduala s linijom normalne distribucije

```
qqnorm(rstandard(selected.model))
qqline(rstandard(selected.model))
```

Normal Q-Q Plot



plot(selected.model\$fitted.values,selected.model\$residuals) #reziduale je dobro prikazati u ovisnosti o



#install.packages("nortest")
#library(nortest)
#require(nortest)

```
\#lillie.test(rstandard(fit.livarea))
```

cor(data\$YearBuilt,data\$SalePrice)

```
## [1] 0.5228973
```

cor.test(data\$YearBuilt,data\$SalePrice)

```
##
## Pearson's product-moment correlation
##
## data: data$YearBuilt and data$SalePrice
## t = 23.424, df = 1458, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.4845947 0.5591987
## sample estimates:
## cor
## 0.5228973</pre>
```